

Challenge Sprint HP

Visão Computacional - José Maia

No challenge da HP, os alunos precisam buscar anúncios de cartuchos piratas nos marketplaces do Brasil

Integrantes

Alan Maximiano RM557088

André Rovai RM555848

Antônio Vinicius RM558014

Leonardo Zago RM558691

Renan de França RM558413

Thiago Almança RM558108

RELATÓRIO ANALÍTICO – SPRINT 1

Challenge HP – Identificação de Diferenças Visuais em Anúncios



1. INTRODUÇÃO

Este relatório apresenta os resultados obtidos no Sprint 1 do *Challenge HP*, cujo foco foi a estruturação inicial de dados visuais de anúncios e o teste de abordagens com Inteligência Artificial (IA) para detectar diferenças visuais relevantes entre peças publicitárias.

Em um cenário publicitário competitivo, a capacidade de diferenciar rapidamente o conteúdo visual de campanhas da própria empresa e de concorrentes é estratégica. Assim, foram exploradas técnicas de classificação por CNNs e similaridade de embeddings, validando a viabilidade das abordagens em um dataset reduzido.

2. HIPÓTESES DEFINIDAS

Foram formuladas quatro hipóteses para orientar os testes:

H1: Classificação de Conteúdo/Tipo de Anúncio (CNN)

- **Descrição:** Uma rede CNN pode distinguir anúncios com base no tipo de produto (ex: *HP Original* vs. *Outros*).
- **Como indica diferença:** Anúncios classificados em categorias diferentes são considerados visualmente distintos.

H2: Similaridade Visual com Embeddings (Modelos Pré-treinados)

- **Descrição:** Embeddings extraídos de modelos como ResNet50 capturam características visuais relevantes.
- **Como indica diferença:** Similaridade de cosseno baixa ou agrupamento em clusters diferentes.

H3: Classificação de Estilo/Atributo (CNN) – Conceitual

- **Descrição:** Uma CNN poderia classificar anúncios por estilo visual (ex: minimalista, colorido).
- **Status:** Não testada neste sprint por depender de dataset rotulado mais amplo.

H4: Detecção de Anomalias (Autoencoders) – Conceitual

- **Descrição:** Autoencoders treinados com o "padrão visual HP" poderiam detectar outliers.
 - **Status:** Também considerado futuro, com base em dataset ampliado.
-

3. METODOLOGIA E DESENVOLVIMENTO

As hipóteses H1 e H2 foram implementadas em Python no Google Colab, com os seguintes conjuntos de dados:

3.1. Conjuntos de Dados Utilizados

- HP_Original: 30 imagens
- Outros: 30 imagens
- general_ads_for_embeddings: 60 imagens

Todas as imagens foram convertidas para formato JPEG, modo RGB, e carregadas no ambiente com compatibilidade para TensorFlow.

3.2. Ferramentas Utilizadas

- Python 3.x
- Google Colab
- TensorFlow e Keras
- Scikit-learn
- Pillow (PIL)
- Matplotlib

3.3. Hipótese 1 – Classificação CNN

- Modelo CNN sequencial:
 - Camada de normalização (Rescaling)
 - Três blocos Conv2D + MaxPooling (filtros 16, 32, 64)
 - Dropout 0.3
 - Camada Densa com 128 neurônios
 - Saída com 1 neurônio e ativação sigmoide
- Função de perda: binary_crossentropy
- Otimizador: adam
- Treinamento: 10 épocas
- Dataset carregado com image_dataset_from_directory (validação: 20%)

3.4. Hipótese 2 – Embeddings com ResNet50


- Modelo: ResNet50 pré-treinado (ImageNet), com include_top=False e pooling='avg'
- Extração de vetores de 2048 dimensões
- Cálculo da similaridade de cosseno entre pares de imagens
- Aplicação de KMeans (k=3) para agrupamento visual

4. RESULTADOS E DISCUSSÃO

H1 – Classificação CNN (Conteúdo/Tipo)


Gráficos de Acurácia e Perda (H1)

- Acurácia de treino atingiu 100% nas últimas épocas.
- Acurácia de validação variou entre 83% e 100%, estabilizando em 100% nas últimas épocas.



- Perda de treino e validação caiu significativamente ao longo das épocas, com valores muito baixos ao final.

Matriz de Confusão – Conjunto de Validação



Discussão H1

A CNN demonstrou excelente desempenho no dataset reduzido, com acurácia perfeita na validação. A perda próxima de zero e a matriz de confusão perfeita indicam boa separação entre classes, mesmo com apenas 60 imagens.

Contudo, devido ao tamanho limitado do dataset, é necessário cautela quanto à generalização do modelo. Resultados tão altos podem ser influenciados por overfitting ou por baixa variabilidade no conjunto.

Sugestões para evolução:

- Expandir o número e variedade de imagens
 - Aplicar data augmentation
 - Realizar validação cruzada com diferentes splits
 - Testar com datasets externos
-

H2 – Similaridade Visual com Embeddings

Resultados

- A matriz de similaridade de cosseno revelou agrupamentos coerentes:
 - Anúncios similares visualmente obtiveram similaridade > 0.85
 - Estilos muito diferentes apresentaram similaridade < 0.5
- O KMeans ($k=3$) gerou clusters visuais:
 - Cluster 1: anúncios escuros com textos marcantes
 - Cluster 2: produtos isolados em fundo branco
 - Cluster 3: estilo lifestyle, com pessoas e elementos coloridos

Discussão H2

A abordagem com embeddings se mostrou eficaz para:

- Comparação visual automatizada entre anúncios
 - Mapeamento de identidade visual
 - Agrupamento sem rótulos prévios
- É uma ferramenta valiosa para análise exploratória e benchmarking visual.

Limitações atuais:

- Análise ainda qualitativa (visual)
 - Métricas de cluster dependem da escolha de k
 - Precisa ser combinada com interpretação de contexto visual
-

5. UTILIZAÇÃO NAS PRÓXIMAS ETAPAS DO CHALLENGE HP

As estratégias do Sprint 1 abrem caminhos para avanços importantes:

Expansão de Dados

- Coletar imagens de campanhas da HP e concorrência
- Adicionar rótulos estilísticos, produtos e campanhas

Análises Automatizadas

- Classificação com CNNs por tipo e estilo (H1 e H3)
- Detecção de anúncios fora do padrão (H4)

Benchmarking Visual com Embeddings (H2)

- Criar mapas visuais do mercado
- Avaliar posicionamento da marca HP
- Comparar visualmente campanhas com e sem sucesso

Aplicações Estratégicas

- Avaliar consistência visual da marca
- Detectar outliers e tendências emergentes
- Ajudar no briefing criativo de novas campanhas

6. CONCLUSÃO DO SPRINT 1

O Sprint 1 demonstrou a viabilidade técnica de identificar diferenças visuais em anúncios, com bons resultados preliminares para:

- CNNs (H1): Classificação por tipo de conteúdo
- Embeddings (H2): Agrupamento e medição de similaridade

As hipóteses H3 (estilo) e H4 (anomalias) foram validadas conceitualmente e deverão ser implementadas com base em um dataset mais robusto.

A aplicação dessas estratégias permitirá à HP:

- Monitorar sua identidade visual
- Avaliar concorrentes com rigor técnico
- Tomar decisões criativas baseadas em dados

O próximo passo essencial é a expansão do dataset e rotulagem cuidadosa, permitindo o desenvolvimento de modelos mais complexos e análises mais granulares.